

PREPOZNAVANJE LICA

KORIŠTENJEM T-SVD METODE

Travanj 2020.

Bratulić Petar
Stanišić Matea



Uvod i notacija

Tenzori višeg reda


- Tenzor je višedimenzionalno polje. U mnogo slučajeva, primjerenije je pohraniti podatke u višedimenzionalnim poljima višeg reda, nego u ekvivalentnoj matričnoj formi.
- Tenzori višeg reda pojavljuju se u primjeni mnogih znanstvenih disciplina poput psihometrije ili obradi signala i slika.
- Rezultat česte primjene su razni algoritmi i dekompozicije koji su razvijeni u tu svrhu poput Higher-Order SVD-a (HOSVD), TUCKER-a ili CANDECOMP/PARAFAC-a (CP).

Dekompozicija tenzora I

■ CP dekompozicija

$$\mathcal{A} = \sum_{l=1}^R u^{(l)} \circ v^{(l)} \circ w^{(l)} \implies (\mathcal{A})_{i,j,k} = \sum_{l=1}^R u_i^{(l)} v_j^{(l)} w_k^{(l)},$$

gdje je \mathcal{A} tenzor dimenzija $I \times J \times K$, $u^{(l)} \in \mathbb{R}^I$, $v^{(l)} \in \mathbb{R}^J$, $w^{(l)} \in \mathbb{R}^K$, za $l = 1, 2, \dots, R$




Slika 1: CP dekompozicija

Dekompozicija tenzora II

■ Tucker dekompozicija

$$\mathcal{A} = \mathcal{G} \times_1 \mathbf{U} \times_2 \mathbf{V} \times_3 \mathbf{W} = \sum_{i=1}^{R_1} \sum_{j=1}^{R_2} \sum_{k=1}^{R_3} \sigma_{ijk} (u^{(i)} \circ v^{(j)} \circ w^{(k)})$$

gdje je $R_1 \leq I, R_2 \leq J, R_3 \leq K$ i za $i, j, k, u^{(i)} \in \mathbb{R}^I, v^{(j)} \in \mathbb{R}^J, w^{(k)} \in \mathbb{R}^K, \mathcal{G} = \sigma_{ijk} \in \mathbb{R}^{R_1 \times R_2 \times R_3}, \mathbf{U} = [u^1, u^2, \dots, u^{R_1}], \mathbf{V} = [v^1, v^2, \dots, v^{R_2}], \mathbf{W} = [w^1, w^2, \dots, w^{R_3}]$



Slika 2: Tucker dekompozicija

Notacija I

■ Red tenzora - modovi

$$\mathcal{A} = (a_{i_1 i_2 \dots i_p}) \in \mathbb{R}^{n_1 \times n_2 \times \dots \times n_p}.$$

■ Nit tenzora

$$A(:, j, k)$$

■ Odsječak tenzora

$A^{(k)} = A(:, :, k), A(:, k, :), A(k, :, :)$ redom označavaju frontalni, lateralni i horizontalni odsječak

Notacija II

- Blok cirkularna matrica veličine $ln \times mn$ (nastala iz $A \in \mathbb{R}^{l \times m \times n}$)

$$\text{bcirc}(\mathcal{A}) = \begin{bmatrix} \mathbf{A}^{(1)} & \mathbf{A}^{(n)} & \mathbf{A}^{(n-1)} & \dots & \mathbf{A}^{(2)} \\ \mathbf{A}^{(2)} & \mathbf{A}^{(1)} & \mathbf{A}^{(n)} & \dots & \mathbf{A}^{(3)} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{A}^{(n)} & \mathbf{A}^{(n-1)} & \mathbf{A}^{(n-2)} & \dots & \mathbf{A}^{(1)} \end{bmatrix}$$

- Unfold

$$\text{unfold}(\mathcal{A}) = \begin{bmatrix} \mathbf{A}^{(1)} \\ \mathbf{A}^{(2)} \\ \vdots \\ \mathbf{A}^{(n)} \end{bmatrix}$$

Notacija III

■ Fold

$$\text{fold}(\text{unfold}(\mathcal{A})) = \mathcal{A}.$$

■ Frobeniusova norma tenzora $A \in \mathbb{R}^{l \times m \times n}$

$$\|\mathcal{A}\|_F = \sqrt{\sum_{i=1}^l \sum_{j=1}^m \sum_{k=1}^n a_{ijk}^2},$$

PCA

PCA - *eigenfaces*

- PCA je jedna od klasičnih tehnika u prepoznavanju slika i kompresiji podataka.
- *glavne komponente* - transformirane nekorelirane varijable dobivene iz velikog broja originalnih varijabli koje su moguće korelirane
- Prvih nekoliko glavnih komponenti objašnjava većinu varijance u podacima, dok ostale imaju mali doprinos.

PCA algoritam

Input: Slike za treniranje: I_i ; Test slika J , indeks kraćenja k

Output: Uspredba test slike sa slikom iz skupa za treniranje

for $i = 1$ to N do

$L(:, i) \leftarrow$ vektorizirani I_i

end for

$A \leftarrow$ srednja devijacijska forma od L

$U \leftarrow$ lijevi singularni vektori od A

$G \leftarrow U(:, 1 : k)^T * A$

$T \leftarrow (J - M)$; M srednja slika

$t \leftarrow$ vektorizirani forma od T

$c \leftarrow U(:, 1 : k)^T * t$

for $j = 1$ to N do

 Izračunaj $\|c - G(:, j)\|_F$

end for

Slika za treniranje čiji su koeficijenti najbliži test slici je rezultat.

Algorithm 1: Tradicionalna matrična PCA metoda

Tensorfaces

TensorFaces

- TensorFaces je bio prvi algoritam koji je koristio tenzore u rješavanju problema prepoznavanja lica.
- Podaci su reprezentirani kao tenzor s različitim modovima za različite faktore. Kao i u PCA, slike su vektorizirane. Ostali modovi se koriste kako bi se reprezentirali ostala svojstva slike.
- Aproksimacija tenzora se postiže multidimenzionalnom metodom *higher-order* SVD (HOSVD).

TensorFaces algoritam I

Input: Slike za treniranje:

$\mathbf{I}_{p,v,t,e}, p = 1, \dots, P, v = 1, \dots, V, i = 1, \dots, I, e = 1, \dots, E;$
 Test slika \mathbf{J}

Output: Koeficijenti testne slike s nekim tenzorskim bazama i usporedbama

for $p = 1 \dots, P, v = 1 \dots, V, i = 1 \dots, I, e = 1 \dots, E$ **do**
 $\mathcal{L}(p, v, i, e, :) \leftarrow$ vektorizirani $\mathbf{I}_{p,v,i,e}$
end for

Napravi HOSVD da se dobije jezgri tenzor \mathcal{Z} i ortogonalne faktorske matrice \mathbf{U}_i :

$\mathcal{L} \leftarrow \mathcal{Z} \times_1 \mathbf{U}_p \times_2 \mathbf{U}_v \times_3 \mathbf{U}_i \times_4 \mathbf{U}_e \times_5 \mathbf{U}_p i x$

$\mathcal{B} \leftarrow \mathcal{Z} \times_2 \mathbf{U}_v \times_3 \mathbf{U}_i \times_4 \mathbf{U}_e \times_5 \mathbf{U}_p i x$

$\mathcal{T}(1, 1, 1, 1, :) \leftarrow$ vektorizirana slika za testiranje

TensorFaces algoritam II

```

for  $v = 1, \dots, V$ ,  $i = 1, \dots, I$ ,  $e = 1, \dots, E$  do
   $c_{v,i,e} \leftarrow (\mathcal{B}_{v,i,e}^\dagger)^T \mathcal{T}(1, 1, 1, 1, :)$ 
  for  $p = 1, \dots, P$  do
    Izračunaj  $\|c_{v,i,e} - \mathbf{U}_p(p, :)^T\|_F$ 
  end for
end for

```

Slika za treniranje čiji su koeficijenti najbliži test slici je rezultat.

Algorithm 2: TensorFaces metoda

Tensor framework

Tenzor - tenzor množenje I

Definicija 4.1

Neka je $\mathcal{A} \in \mathbb{R}^{l \times p \times n}$ i $\mathcal{B} \in \mathbb{R}^{p \times m \times n}$, tada definiramo produkt tenzora $\mathcal{A} * \mathcal{B}$ kao $l \times m \times n$ tenzor

$$\mathcal{A} * \mathcal{B} = \text{fold}(\text{bcirc}(\mathcal{A}) \cdot \text{unfold}(\mathcal{B})) \quad (1)$$

U praksi tenzor - tenzor množenje računamo malo drukčije. Pretpostavimo da je $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ i \mathbf{F}_n je $n \times n$ DFT matrica. Dobivamo $\text{bcirc}(\mathcal{A})$ koja je $n \times n$ blok matrica s $l \times m$ blokova. Nakon kratke manipulacije dobivamo:

Tensor - tenzor množenje II

$$\begin{aligned}
 (\mathbf{F}_n \otimes \mathbf{I}_l) \text{bcirc}(\mathcal{A}) (\mathbf{F}_n^* \otimes \mathbf{I}_m) &= \mathbf{P}_1^T \begin{bmatrix} \mathbf{D}_{11} & \mathbf{D}_{12} & \cdots & \mathbf{D}_{1m} \\ \mathbf{D}_{21} & \mathbf{D}_{22} & \cdots & \mathbf{D}_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{D}_{l1} & \mathbf{D}_{l3} & \cdots & \mathbf{D}_{lm} \end{bmatrix} \mathbf{P}_2^T \\
 &= \begin{bmatrix} \hat{\mathbf{A}}^{(1)} & & & \\ & \hat{\mathbf{A}}^{(2)} & & \\ & & \ddots & \\ & & & \hat{\mathbf{A}}^{(n)} \end{bmatrix}.
 \end{aligned}$$

Tenzor - tenzor množenje III

Primijenjujući brzu Fourierovu transformaciju duž trećeg moda \mathcal{A} daje nam alternativni način računanju $\hat{\mathbf{A}}^{(i)}$.

Input: $\mathcal{A} \in \mathbb{R}^{l \times p \times n}, \mathcal{B} \in \mathbb{R}^{p \times m \times n}$

Output: $\mathcal{C} := \mathcal{A} * \mathcal{B}$

$\hat{\mathcal{A}} \leftarrow \text{fft}(\mathcal{A}, [], 3); \hat{\mathcal{B}} \leftarrow \text{fft}(\mathcal{B}, [], 3)$

for $i = 1$ **to** n **do**

$\hat{\mathcal{C}}(:, :, i) \leftarrow \hat{\mathcal{A}}(:, :, i) \hat{\mathcal{B}}(:, :, i)$

end for

$\mathcal{C} \leftarrow \text{ifft}(\hat{\mathcal{C}}, [], 3)$

Algorithm 3: Tenzor - tenzor množenje, koristeći računanje u Fourierovoj domeni

Pojmovi i svojstva potrebni za T-SVD I


Lema 4.1

$$\mathcal{A} * (\mathcal{B} * \mathcal{C}) = (\mathcal{A} * \mathcal{B}) * \mathcal{C}$$

Definicija 4.2

Ako je \mathcal{A} tenzor dimenzija $l \times m \times n$, onda je \mathcal{A}^T tenzor dimenzija $m \times l \times n$ dobiven transponiranjem svakog frontalnog odsječka te mijenjanjem poretka transponiranih frontalnih odsječaka od 2 do n .

Pojmovi i svojstva potrebni za T-SVD II



Slika 3: Transponiranje

Definicija 4.3

Kažemo da je tenzor f-dijagonalan ako je svaki frontalni odsječak dijagonalna matrica.

Pojmovi i svojstva potrebni za T-SVD III

Definicija 4.4

Tenzor dimenzija $I \times I \times n$ \mathcal{I}_{II_n} je identiteta čiji je prvi frontalni odsječak $I \times I$ matrica identiteta, a svi ostali frontalni odsjeci su nulmatrice.

Definicija 4.5

Tenzor realnih vrijednosti \mathcal{Q} dimenzija $I \times I \times n$ je ortogonalan ako

$$\mathcal{Q}^T * \mathcal{Q} = \mathcal{Q} * \mathcal{Q}^T = \mathcal{I}. \quad (2)$$

T-SVD

T-SVD dekompozicija

Teorem 5.1

Neka je \mathcal{A} tenzor realnih vrijednosti dimenzija $l \times m \times n$. Tada se \mathcal{A} može faktorizirati u obliku

$$\mathcal{A} = \mathcal{U} * \mathcal{S} * \mathcal{V}^T$$

pri čemu su \mathcal{U} ortogonalni tenzor dimenzija $l \times l \times n$, \mathcal{V} ortogonalni tenzor dimenzija $m \times m \times n$ te \mathcal{S} f-dijagonalni tenzor dimenzija $l \times m \times n$.

Dokaz teorema 5.1 I


Prvo, transformirajmo $\text{bcirc}(\mathcal{A})$ u Fourierovu domenu:

$$(\mathbf{F}_n \otimes \mathbf{I}_l) \text{bcirc}(\mathcal{A}) (\mathbf{F}_n^* \otimes \mathbf{I}_m) = \begin{bmatrix} \hat{\mathbf{A}}^{(1)} & & & \\ & \hat{\mathbf{A}}^{(2)} & & \\ & & \ddots & \\ & & & \hat{\mathbf{A}}^{(n)} \end{bmatrix}$$

Izračunajmo matrični SVD za svaki $\hat{\mathbf{A}}^{(i)}$ kao $\hat{\mathbf{A}}^{(i)} = \hat{\mathbf{U}}^{(i)} \hat{\mathbf{S}}^{(i)} (\hat{\mathbf{V}}^{(i)})^T$

Sada nakon što izaberemo odgovarajuće dimenzije za \mathbf{I} , primijenimo $\mathbf{F}_n^* \otimes \mathbf{I}$ s lijeva i $\mathbf{F}_n \otimes \mathbf{I}$ s desna svake blok dijagonalne matrice da dobijemo tri cirkularne matrice čiji su prvi blok stupci $\text{unfold}(\mathcal{U})$, $\text{unfold}(\mathcal{S})$, $\text{unfold}(\mathcal{V}^T)$. Primijenjujući fold dobivamo \mathcal{U} , \mathcal{S} , \mathcal{V}^T .

Dokaz teorema 5.1 II



Slika 4: T-SVD

Korištenje T-SVD-a u dekompoziciji slika

- Predložena metoda razlikuje se od PCA za matrice na način da se podaci čuvaju u tenzorima trećeg reda te se koriste tenzor-teznor faktORIZACIJE bazirane na operatoru $*$.
- razlikuje se od TensorFaces algoritma jer slike nisu pikselizirane, nema dodatnih dimenzija koje predstavljaju osvjetljenje, poze i slično te koristi T-SVD umjesto HOSVD-a.


Squeeze i Twist operacije I

- U postupku će nam koristiti sljedeća notacija: squeeze operacija koja uzima tenzor \mathcal{X} iz $\mathbb{R}^{l \times 1 \times n}$ i daje matricu

$$\mathbf{X} := \text{squeeze}(\mathcal{X}) \Rightarrow \mathbf{X}(i, j) := \mathcal{X}(i, 1, j)$$

dok je twist inverzna operacija operaciji squeeze

$$\text{twist}(\text{squeeze}(\mathcal{X})) = \mathcal{X}.$$



Slika 5: Prikaz operacija squeeze i twist

Algoritam T-SVD 1

Input: Slike za treniranje: \mathbf{I}_i ; Test slika \mathbf{J} , indeks kraćenja k

Output: Odgovarajuća slika za test sliku iz skupa za treniranje

for $i = 1$ to N do

$\mathcal{L}(:, i, :) \leftarrow \mathbf{I}_i$

end for

$\mathbf{M} \leftarrow$ srednja slika

$\mathcal{A} \leftarrow$ srednja devijacijska forma od \mathcal{L}

$\mathcal{U} \leftarrow$ lijevi singularni vektori tenzora \mathcal{A}

$\mathcal{C} \leftarrow \mathcal{U}(:, 1:k, :)^T * \mathcal{A}$

$\mathcal{T}(:, 1, :) \leftarrow \text{twist}(\mathbf{J} - \mathbf{M})$

$\mathcal{B} \leftarrow \mathcal{U}(:, 1:k, :)^T * \mathcal{T}$

for $j = 1$ to N do

Izračunaj $\|\mathcal{B} - \mathcal{C}(:, j, :)\|_F$

end for

Slika za treniranje čiji su koeficijenti najbliži test slici je rezultat.

Poboljšani T-SVD I

Ako označimo

- $\mathbf{Y}_j := \text{squeeze}(\mathbf{A}(:, j, :))$ j -tu sliku za treniranje
- $\text{circ}(v)$ cirkularnu matricu čiji je prvi stupac v

onda se može pokazati da je

$$\mathbf{Y}_j \approx \sum_{t=1}^k \mathbf{W}_t \text{circ}(\mathbf{c}_{t,j}) \quad (3)$$

gdje su

- $\mathbf{W}_t := \text{squeeze}(\mathcal{U}(:, t, :)) \in \mathbb{R}^{l \times n}$ matrica
- $\mathbf{c}_{t,j}^T := \text{squeeze}(\mathbf{C}(t, j, :))^T$ vektor redak duljine n

Poboljšani T-SVD II

Teorem 5.2

Neka \mathbf{F} predstavlja $n \times n$ DFT matricu. Neka su $\widehat{\mathbf{Y}}_j := \mathbf{Y}_j \mathbf{F}$, $\widehat{\mathbf{W}}_j := \mathbf{W}_j \mathbf{F}$ i $\widehat{\mathbf{c}}_{t,j}$ Fourierovi koeficijenti vektora stupca $\mathbf{c}_{t,j}$ duljine n ,

$$\widehat{\mathbf{Y}}_j \approx \left[\sum_{t=1}^k \widehat{\mathbf{c}}_{t,j}^{(1)} \widehat{\mathbf{U}}^{(1)}(:, t), \sum_{t=1}^k \widehat{\mathbf{c}}_{t,j}^{(2)} \widehat{\mathbf{U}}^{(2)}(:, t), \dots, \sum_{t=1}^k \widehat{\mathbf{c}}_{t,j}^{(n)} \widehat{\mathbf{U}}^{(n)}(:, t) \right] \quad (4)$$

gdje $\widehat{\mathbf{c}}_{t,j}^{(i)}$ predstavlja i -tu komponentu tog vektora i
 $\widehat{\mathbf{W}}_t(:, i) = \widehat{\mathbf{U}}^{(i)}(:, t)$, gdje je $\widehat{\mathbf{U}}^{(i)}$ unitarna matrica iz dokaza teorema T-SVD-a. Slijedi da je algoritam 2 ekvivalentan simultanoj PCA izvršenoj na svakom stupcu transformirane slike u Fourireovom prostoru, koristeći iste indekse kraćenja k na svakom stupcu.

Poboljšani T-SVD III

Rezultat:

$$\widehat{\mathbf{Y}}_j \approx \left[\sum_{t=1}^{k_1} \widehat{\mathbf{c}}_{\mathbf{t},j}^{(1)} \widehat{\mathbf{U}}^{(1)}(:, t), \sum_{t=1}^{k_2} \widehat{\mathbf{c}}_{\mathbf{t},j}^{(2)} \widehat{\mathbf{U}}^{(2)}(:, t), \dots, \sum_{t=1}^{k_n} \widehat{\mathbf{c}}_{\mathbf{t},j}^{(n)} \widehat{\mathbf{U}}^{(n)}(:, t) \right], \quad (5)$$

gdje, da bi sačuvali konjugatnu simetriju, indeks kraćenja za stupce j , $2 \leq j \leq \frac{n}{2}$ je isti kao i za stupce $n - j + 2$.

Tada je suma svih indeksa kraćenja jednaka

$$K = k_1 + 2k_2 + \dots + 2k_{\frac{n}{2}} + k_{\frac{n}{2}+1} \quad (6)$$

Računanje parametara kraćenja $k_i, i = 1, \dots, \frac{n}{2} + 1$

- Vrijedi:

$$\|\hat{\mathbf{A}}(:, :, 1 : \frac{n}{2} + 1)\|_F^2 = \sum_{i=1}^{\frac{n}{2}+1} \|\hat{\mathbf{A}}(:, :, i)\|_F^2 = \sum_{i=1}^{\frac{n}{2}+1} \sum_{j=1}^{\min(l,m)} (\hat{\mathbf{s}}_j^{(i)})^2 \quad (7)$$

- Mjera relativne energije:

$$\frac{\sum_{i=1}^{\frac{n}{2}+1} \sum_{j=1}^{k_i} (\hat{\mathbf{s}}_j^{(i)})^2}{\|\hat{\mathbf{A}}(:, :, 1 : \frac{n}{2} + 1)\|_F^2} \quad (8)$$

- Parametre kraćenja računamo traženjem najmanjeg indeksa t za koji vrijedi, uz oznaku *threshold* za relativnu energijsku vrijednost, i \mathbf{q} za vektor koji sadrži $\hat{\mathbf{s}}_j^{(i)}$ od najveće do najmanje:

$$\sum_{i=1}^{\frac{n}{2}+1} \sum_{j=1}^{k_i} \{(\hat{\mathbf{s}}_j^{(i)})^2 : (\hat{\mathbf{s}}_j^{(i)})^2 > \mathbf{q}(t)^2\} > \|\hat{\mathbf{A}}(:, :, 1 : \frac{n}{2} + 1)\|_F^2 \times \text{threshold} \quad (9)$$

- Kako vrijedi $\hat{\mathbf{s}}_1^{(i)} \geq \hat{\mathbf{s}}_2^{(i)} \geq \dots \hat{\mathbf{s}}_{\min\{l,m\}}^{(i)}$, k_i se definiraju tako da je $\hat{\mathbf{s}}_{k_i}^{(i)} > \mathbf{q}(t)$, ali $\hat{\mathbf{s}}_{k_i+1}^{(i)} \leq \mathbf{q}(t)$

Algoritam T-SVD 2 I

Input: Slike za treniranje: \mathbf{I}_i , $i = 1, 2, \dots, N$; Test slika \mathbf{J} , indeks kraćenja k

Output: Usporedba test slike s reprezentacijom skupa za treniranje u Fourierovoj domeni

for $i = 1$ **to** N **do**

$\mathcal{L}(:, :, i) \leftarrow \mathbf{I}_i$

end for

$\mathcal{M} \leftarrow$ srednja slika

$\mathcal{A} \leftarrow$ srednja devijacijska forma od \mathcal{L}

Frontalni odsječci SVD-a od $\hat{\mathbf{A}}^{(i)} \leftarrow \hat{\mathcal{A}}(:, :, i)$, $i = 1, \dots, \frac{n}{2} + 1$

Drop strategija; sadrži jedino $\hat{\mathbf{U}}^{(i)}(:, 1 : k_i)$

$\mathcal{T}(:, 1, :) \leftarrow \text{twist}(\mathbf{J} - \mathcal{M})$

for $i = 1 : \frac{n}{2} + 1$, $t = 1 : k_t$, $j = 1 : N$ **do**

$\hat{\mathbf{c}}_{t,j}^{(i)} \leftarrow (\hat{\mathbf{U}}^{(i)}(:, t))^H \hat{\mathbf{A}}^{(i)}(:, j)$

end for

Algoritam T-SVD 2 II

for $i = 1 : \frac{n}{2} + 1$, $t = 1 : k_t$ **do**
 $\hat{\mathbf{b}}_t^{(i)} \leftarrow (\hat{\mathbf{U}}^{(i)}(:, t))^H \hat{\mathbf{T}}^{(i)}(:, 1)$

end for

for $j = 1 : N$ **do**

 Izračunaj $\|\hat{\mathbf{b}}_t^{(i)} - \hat{\mathbf{c}}_{t,j}^{(i)}\|_F$


end for

Slika za treniranje čiji su koeficijenti najbliži test slici je rezultat.

T-PQ

Alternativni pristup pomoću tenzorske QR faktorizacije I

Alternativna metoda tenzorske faktorizacije s potencijalnom prednošću u slučaju ažuriranja baze lica, ali s nedostatkom da faktorizacija neće biti optimalna.



Slika 6: Ažuriranje baze podataka

Alternativni pristup pomoću tenzorske QR faktorizacije II

Definicija 6.1

Permutacijski tenzor $\mathcal{B} \in \mathbb{R}^{m \times m \times n}$ je tenzor čiji su elementi nule i jedinice te vrijedi:

$$\mathcal{P}^T * \mathcal{P} = \mathcal{P} * \mathcal{P}^T = \mathcal{I}. \quad (10)$$

Teorem 6.1

Neka je $\mathcal{A} \in \mathbb{R}^{l \times m \times n}$ tenzor realnih vrijednosti. Tada se \mathcal{A} može faktorizirati u obliku

$$\mathcal{A} * \mathcal{P} = \mathcal{Q} * \mathcal{R} \quad (11)$$

gdje je $\mathcal{Q} \in \mathbb{R}^{l \times l \times n}$ ortogonalni tenzor, $\mathcal{R} \in \mathbb{R}^{l \times m \times n}$ f-gornje trokutasti tenzor i \mathcal{P} permutacijski tenzor.

Dokaz Teorema 6.1

- Prebacimo se u Fourierovu domenu
- Napravimo QR -faktorizacije pivotirane po stupcima:

$$\hat{\mathbf{A}}^{(1)} \mathbf{P}^{(1)} = \hat{\mathbf{Q}}^{(1)} \hat{\mathbf{R}}^{(1)} \quad (12)$$

$$\hat{\mathbf{A}}^{(i)} \mathbf{P}^{(1)} = \hat{\mathbf{Q}}^{(i)} \hat{\mathbf{R}}^{(i)} \quad (13)$$

- Definiramo

$$\mathbf{P} := (\mathbf{F}^* \otimes \mathbf{I})(\text{blok dijagonalna matrica sa } \mathbf{P}^{(1)} \text{ na glavnim dijagonalama}) (\mathbf{F} \otimes \mathbf{I}) \quad (14)$$

$$\hat{\mathbf{Q}} = (\mathbf{F}^* \otimes \mathbf{I})(\text{blok dijagonalna matrica sa } \hat{\mathbf{Q}}^{(i)} \text{ na glavnim dijagonalama}) (\mathbf{F} \otimes \mathbf{I}) \quad (15)$$

$$\hat{\mathbf{R}} = (\mathbf{F}^* \otimes \mathbf{I})(\text{blok dijagonalna matrica sa } \hat{\mathbf{R}}^{(i)} \text{ na glavnim dijagonalama}) (\mathbf{F} \otimes \mathbf{I}) \quad (16)$$

- $\mathcal{P}, \mathcal{Q}, \mathcal{R}$ dobivamo primijenjujući `fold` na prvi blok stupac blok cirkularnih matrica 14, 15 i 16, respektivno.

Algoritam za T-QR

Input: Slike za treniranje: \mathbf{I}_i , $i = 1, 2, \dots, N$; Test slika \mathbf{J} , indeks kraćenja k

Output: Koeficijenti testnih slika s bazom smanjene dimenzije

for $i = 1$ **to** N **do**

$\mathcal{L}(:, :, i) \leftarrow \mathbf{I}_i$

end for

$\mathcal{M} \leftarrow$ srednja slika

$\mathcal{A} \leftarrow$ srednja devijacijska forma od \mathcal{L}

$[\mathbf{Q}, \mathcal{R}] \leftarrow$ tenzor (pivotirana) QR dekompozicija od \mathcal{A}

$\mathcal{C} \leftarrow \mathbf{Q}(:, 1:k, :)^T * \mathcal{A}$

$\mathcal{T}(:, 1, :) \leftarrow \text{twist}(\mathbf{J} - \mathcal{M})$

$\mathcal{B} \leftarrow \mathbf{Q}(:, 1:k, :)^T * \mathcal{T}$

for $j = 1$ **to** N **do**

Izračunaj $\|\mathcal{B} - \mathcal{C}(:, j, :)\|_F$

end for

Slika za treniranje čiji su koeficijenti najbliži test slici je rezultat.

Rezultati

Podaci

- Slike preuzete iz [7] korišteni su po uzoru na [2]



Slika 7: Primjer fotografija iz preuzete baze podataka [7]

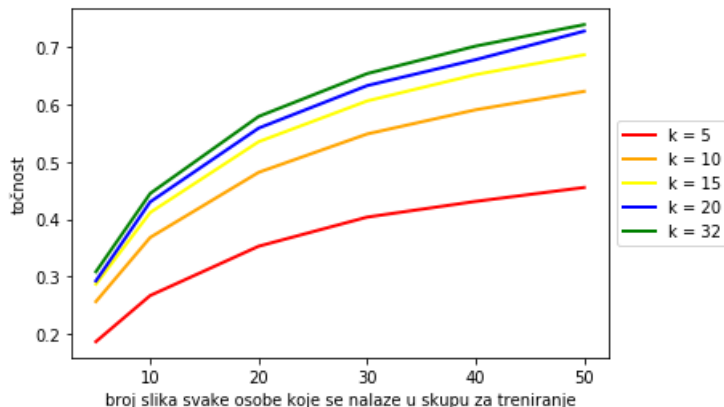
- Preuzeta baza podataka sadrži 16128 slika 28 osoba uslikanih u 9 različitih pozicija i u 64 različita osvjetljenja

Testiranje

- Matlab okruženje
- Faza *treniranja* i *testiranja*
- $p = 5, 10, 20, 30, 40, 50$ predstavlja broj različitih slika svake osobe koje se nalaze u skupu za treniranje te je za svaki p na nasumičan način generirano 50 mogućnosti skupa za treniranje, odnosno skupa za testiranje algoritma
- Za svaki p pokrenuli smo algoritme na svih 50 mogućnosti i usporedili rezultate
- Točnost algoritma određivali smo formulom:

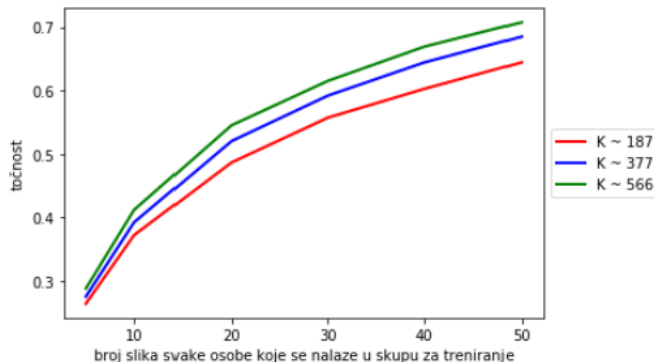
$$\frac{\text{broj dobro prepoznatih lica}}{\text{broj testnih fotografija}} \quad (17)$$

Rezultati - TSVD I



Slika 8: Rezultati pokretanja algoritma koji koristi TSVD metodu dekompozicije tenzora s fiksnim indeksom suženja k na podacima iz [7].


Rezultati - TSVD II



Slika 9: Rezultati pokretanja algoritma koji koristi TSVD metodu dekompozicije tenzora s različitim indeksima kraćenja k_i na podacima iz [7].

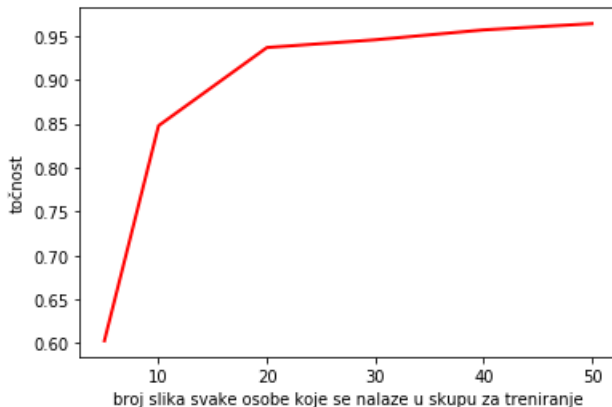
Rezultati - TSVD III

Rezultati - TQR




Slika 10: Rezultati pokretanja algoritma koji koristi TQR metodu dekompozicije tenzora na podacima iz [7].

Rezultati - HOSVD




Slika 11: Rezultati pokretanja algoritma koji koristi HOSVD metodu dekompozicije tenzora na podacima iz [7].

Zaključak




Slika 12: Usporedba svih rezultata pokretanja prethodno navedenih algoritma na podacima iz [7].

Fotografije prije i poslije primjena TSVD-a



Slika 13: Primjer dobro prepoznatih lica



Slika 14: Primjer loše prepoznatih lica

Primjena TSVD metode na video

▶ [Link](#)



Slika 15: Video prije i nakon primjene TSVD-a na njegov tenzor podataka

Literatura

Literatura I



A.S. Georghiades, P.N. Belhumeur i D.J. Kriegman. „From Few to Many: Illumination Cone Models for Face Recognition under Variable Lighting and Pose”. *IEEE Trans. Pattern Anal. Mach. Intelligence* 23.6 (2001), str. 643–660.



Ning Hao i dr. „Facial Recognition Using Tensor-Tensor Decompositions”. *SIAM Journal on Imaging Sciences [electronic only]* 6 (veljača 2013). doi: 10.1137/110842570.



M.E. Kilmer, C.D. Martin i L. Perrone. „A third-order generalization of the matrix svd as a product of third-order tensors”. *Tufts Computer Science Technical Report* (2008).



Liang Liao i Stephen Maybank. „Generalized Visual Information Analysis Via Tensorial Algebra”. *Journal of Mathematical Imaging and Vision* (veljača 2020). doi: 10.1007/s10851-020-00946-9.

Literatura II



Neil Muller, Lourenço Magaia i Ben Herbst. „Singular Value Decomposition, Eigenfaces, and 3D Reconstructions”. *Society for Industrial and Applied Mathematics* 46 (rujan 2004), str. 518–545.



Berkant Savas i Lars Eldén. „Handwritten digit classification using higher order singular value decomposition”. *Pattern Recognit.* 40 (2007), str. 993–1003.



The Extended Yale Face Database B. <http://vision.ucsd.edu/~leekc/ExtYaleDatabase/ExtYaleB.html>..
Dohvaćeno: 30.3.2020.